

Παραγωγή Συνθετικών Δεδομένων Ροής Κυκλοφορίας Με GANs

Project Εαρινού Εξαμήνου
2024-2025



Φίλιππος-Παρασκευάς Ζυγούρης

A.M: 1084660

Εμμανουήλ Λουκάς Ζάννος

A.M: 1084543

Περιεχόμενα

Περίληψη	2
1. Εισαγωγή	3
1.1 Σκοπός και Κίνητρο της Εργασίας	3
1.2 Περιγραφή του Συνόλου Δεδομένων	4
1.3 Οργάνωση και Μεθοδολογία της Εργασίας	5
2. Κατανόηση	6
2.1 Αρχιτεκτονική των GANs	6
2.2 Μαθηματική Θεμελίωση των GANs	7
Σχήμα 1.1: Στόχος της Γενετικής Μοντελοποίησης — Εκμάθηση της Παραμετρικής Κατανομής $P_\theta(X)$ που Προσεγγίζει την Άγνωστη Αληθινή Κατανομή $P(X)$ των Δεδομένων.	7
Σχήμα 1.2: Τα GANs μαθαίνουν να μετασχηματίζουν θόρυβο από μια γνωστή κατανομή $P_z(Z)$ σε δεδομένα που ακολουθούν την επιθυμητή κατανομή $P_\theta(X)$, μέσω της διαδικασίας μάθησης της γεννήτριας.	8
Σχήμα 1.3: Ο Ρόλος της Γεννήτριας (Παραχαράκτη) στα GANs — Χαρτογράφηση της Κατανομής Θορύβου $P_z(Z)$ στην Παραγόμενη Κατανομή $P_G(X)$ με Στόχο την Προσέγγιση της Αληθινής Κατανομής $P(X)$	8
Σχήμα 1.4: Ο Ρόλος του Διαχωριστή (Τραπεζικού Υπαλλήλου) στα GANs — Διάκριση Μεταξύ Πραγματικών και Παραγόμενων Δειγμάτων	9
2.3 Αρχιτεκτονική WGAN	9
Σχήμα 1.5: Συγκριτική απεικόνιση της λειτουργίας διαχωριστή (Discriminator) και κριτή (Critic) στα GAN και WGAN, μέσα από το παράδειγμα της παραχάραξης χαρτονομισμάτων	10
2.4 Μαθηματική Θεμελίωση WGAN	10
Μαθηματικός Τύπος 1.1: Δυσκότητα Kantorovich-Rubinstein για την Απόσταση Wasserstein	11
2.5 Αρχιτεκτονική WGAN-GP	11
2.6 Μαθηματική Θεμελίωση WGAN-GP	12
Μαθηματικός Τύπος 1.2: Εφαρμογή Ποινής Κλίσης (Gradient Penalty) στη Συνάρτηση Απώλειας του WGAN-GP για την Ικανοποίηση της Συνθήκης 1-Lipschitz	13
3. Προετοιμασία Δεδομένων και Υλοποίηση Μοντέλου	13
3.1 Προεπεξεργασία Δεδομένων	13
Σχήμα 1.6: Οπτική αποτύπωση των συσχετίσεων και της διασποράς των μεταβλητών τηλεπικοινωνιακής δραστηριότητας	14
3.2 Υλοποίηση Μοντέλου	14
3.3 Διαδικασία Εκπαίδευσης και Ρύθμιση Υπερπαραμέτρων	16
4. Αξιολόγηση Αποτελεσμάτων	18

4.1 Μέτρηση fidelity (Ομοιότητα με τα Πραγματικά Δεδομένα)	18
4.2 Μέτρηση diversity (Εύρος και Ποικιλία Συνθετικών Δειγμάτων).....	18
4.3 Ανάλυση Επιρροής Υπερπαραμέτρων στο Τελικό Αποτέλεσμα και Αξιολόγηση Αποτελέσματος	19
Σχήμα 1.7: Σύγκριση Πραγματικών και Συνθετικών Δεδομένων Τηλεπικοινωνιακής Δραστηριότητας (πρώτα 100 δείγματα)	20
Πίνακας 1.1: Εξέλιξη Μετρικών Ποιότητας και Ποικιλίας των Συνθετικών Δεδομένων ανά Αριθμό Epochs.....	21
5. Συμπεράσματα και Μελλοντική Έρευνα	22
5.1 Κύρια ευρήματα.....	22
5.2 Προτάσεις για Περαιτέρω Έρευνα – Μελλοντικές Μελέτες.....	23
5.3 Επίκαιρη Εφαρμογή - Ρεαλιστικό Παράδειγμα	23
Σχήμα 1.8: Αρχιτεκτονική WGAN-GP για Ανίχνευση Ανωμαλιών σε Τηλεπικοινωνιακά Δίκτυα 5G – Ροή Εφαρμογής και Πρακτικό Παράδειγμα Χρήσης.....	25
6. Βιβλιογραφία	25

Περίληψη

Η παρούσα εργασία πραγματεύεται τη χρήση Generative Adversarial Networks (GANs), για τη δημιουργία ρεαλιστικών συνθετικών χρονοσειρών δεδομένων τηλεπικοινωνιακής κίνησης. Κύριος στόχος είναι η ενίσχυση της διαθεσιμότητας και η διασφάλιση της ιδιωτικότητας των δεδομένων, επιτρέποντας την ερευνητική και τεχνολογική αξιοποίησή τους, ακόμη και σε σενάρια όπου τα πραγματικά δεδομένα είναι περιορισμένα ή αυστηρά προστατευμένα.

Ειδικότερα, αξιοποιείται το σύνολο δεδομένων τηλεπικοινωνιακής δραστηριότητας (SMS, κλήσεις, internet) από το δίκτυο της περιοχής του Μιλάνου, εστιάζοντας σε δεδομένα μιας ημέρας, με σκοπό την εκπαίδευση ενός βαθιού νευρωνικού δικτύου τύπου Wasserstein GAN με Gradient Penalty (WGAN-GP). Το μοντέλο εκπαιδεύεται αντιπαραθετικά ώστε να μάθει και να αναπαράγει με ακρίβεια τη στατιστική κατανομή και τα σύνθετα πρότυπα της κυκλοφορίας του δικτύου, δημιουργώντας συνθετικές χρονοσειρές που προσομοιώνουν τα χαρακτηριστικά των πραγματικών δεδομένων.

Η υλοποίηση βασίζεται σε ειδικά σχεδιασμένη αρχιτεκτονική και προηγμένες τεχνικές σταθεροποίησης, όπως η χρήση Wasserstein loss και η επιβολή του Lipschitz περιορισμού μέσω gradient penalty, ώστε να διασφαλίζεται η σταθερότητα της εκπαίδευσης και η παραγωγή δεδομένων υψηλής πιστότητας και ποικιλίας. Η αξιολόγηση των συνθετικών δεδομένων πραγματοποιείται με τη χρήση μετρικών ομοιότητας (MSE, Cosine Similarity, KL Divergence) και ποικιλίας (Variance, Coverage), επιβεβαιώνοντας ότι τα παραγόμενα δείγματα διατηρούν τις βασικές στατιστικές και δομικές ιδιότητες των πραγματικών δεδομένων.

Η εργασία αναδεικνύει τη σημασία της παραγωγής συνθετικών δεδομένων για την ασφάλεια και την ανωνυμία σε τηλεπικοινωνιακά δίκτυα, προσφέροντας ένα σύγχρονο εργαλείο για την εκπαίδευση συστημάτων ανίχνευσης ανωμαλιών, καθώς και για την πρακτική ανάπτυξη αξιόπιστων και ευέλικτων λύσεων σε περιβάλλοντα 5G. Η προτεινόμενη μεθοδολογία ανοίγει νέους δρόμους τόσο για την επιστημονική έρευνα όσο και για την εφαρμοσμένη υλοποίηση σε πραγματικές συνθήκες.

1. Εισαγωγή

1.1 Σκοπός και Κίνητρο της Εργασίας

Η γενετική μοντελοποίηση (Generative Modeling) αποτελεί μία από τις πιο καινοτόμες και ταχέως εξελισσόμενες κατευθύνσεις στη σύγχρονη μηχανική μάθηση. Δίνει τη δυνατότητα στα μοντέλα να μαθαίνουν και να αναπαριστούν με ακρίβεια τη στατιστική κατανομή των δεδομένων, παράγοντας νέα, ρεαλιστικά δείγματα που αντικατοπτρίζουν πιστά τα χαρακτηριστικά και τα πρότυπα του αρχικού συνόλου δεδομένων. Σε αντίθεση με την παραδοσιακή εποπτευόμενη μάθηση, η οποία επικεντρώνεται κυρίως στην πρόβλεψη ετικετών ή τιμών βάσει εισόδου, η γενετική μοντελοποίηση επιδιώκει τη δημιουργία συνθετικών δεδομένων τα οποία μιμούνται σε τέτοιο βαθμό τα πραγματικά, ώστε ακόμη και ένας εξειδικευμένος παρατηρητής να δυσκολεύεται να διακρίνει τις διαφορές που υπάρχουν. Αυτή η εξέλιξη έχει ανοίξει τον δρόμο για πληθώρα εφαρμογών, όπως είναι η παραγωγή ρεαλιστικών εικόνων, μουσικής ή κειμένων, προσφέροντας με αυτό το τρόπο νέες δυνατότητες σε τομείς που εκτείνονται από τη βιομηχανία της ψυχαγωγίας έως την ιατρική διάγνωση. Επομένως, η ουσία βρίσκεται στο ότι το μοντέλο “κατανοεί” τη στατιστική φύση των δεδομένων, με τρόπο που του επιτρέπει να αναπαράγει ακόμη και τα πιο περίπλοκα μοτίβα, τα οποία συχνά διαφεύγουν από τις απλές αναλυτικές μεθόδους.

Ειδικά στον τομέα των νευρωνικών δικτύων, η γενετική μοντελοποίηση έχει γνωρίσει ραγδαία ανάπτυξη χάρη στην ανάπτυξη των Generative Adversarial Networks (GANs), η οποία έχει καταστήσει δυνατή την παραγωγή συνθετικών δεδομένων υψηλής ποιότητας, τα οποία συχνά είναι αδύνατο να διακριθούν από τα αληθινά. Τα GANs έχουν επιλύσει σημαντικές προκλήσεις, επιτυγχάνοντας έτσι υψηλό βαθμό στατιστικής ομοιότητας και ρεαλισμού μεταξύ των παραγόμενων και των πραγματικών δεδομένων. Ως εκ τούτου, προσφέρουν στους ερευνητές και τις επιχειρήσεις ένα ισχυρό εργαλείο για τη δημιουργία δεδομένων στον τομέα όπου οι παραδοσιακές μέθοδοι αδυνατούν να ανταποκριθούν αποτελεσματικά στις απαιτήσεις ασφάλειας, ποιότητας και ποικιλίας.

Από την άλλη, στον τομέα της κινητής τηλεφωνίας, ένα από τα βασικά κίνητρα για την παραγωγή συνθετικών δεδομένων είναι η διαχείριση του ζητήματος της ιδιωτικότητας και της διαθεσιμότητας των πραγματικών δεδομένων κίνησης. Παρόλο που τα αληθινά δεδομένα συχνά ανωνυμοποιούνται από τους παρόχους τους, η διάθεσή τους παραμένει περιορισμένη λόγω ανησυχιών που προκύπτουν σχετικά με την προστασία των προσωπικών δεδομένων και τον κίνδυνο διαρροής

ευαίσθητων πληροφοριών. Η δημιουργία συνθετικών δεδομένων με τη χρήση γενετικών μοντέλων δίνει τη δυνατότητα να διατεθούν δεδομένα που δεν αντιστοιχούν σε καμία πραγματική εγγραφή χρήστη ή κελιού, αλλά μιμούνται πιστά τις στατιστικές ιδιότητες των αρχικών δεδομένων. Αυτό το χαρακτηριστικό, επομένως, επιτρέπει την ασφαλή κοινοποίηση των δεδομένων για ερευνητικούς και επιχειρησιακούς σκοπούς, χωρίς να παραβιάζεται έτσι το απόρρητο των συνδρομητών.

Επιπλέον, η γενετική μοντελοποίηση προσφέρει ένα σημαντικό όφελος ως προς τη διαθεσιμότητα των δεδομένων, διευκολύνοντας τη συνεργασία μεταξύ ερευνητών, πανεπιστημίων και εταιρειών, χωρίς να τίθενται σε κίνδυνο τα προσωπικά δεδομένα των χρηστών. Τα συνθετικά δεδομένα μπορούν να διαμοιράζονται ελεύθερα, ενισχύοντας την ανάπτυξη περισσότερο καινοτόμων τεχνικών, τη δοκιμή αλγορίθμων και την υλοποίηση πειραμάτων μεγάλης κλίμακας. Στο πλαίσιο αυτής της εργασίας, επικεντρωνόμαστε στην παραγωγή συνθετικών δεδομένων κινητής τηλεφωνίας, με σκοπό να υποστηρίξουμε και να βελτιώσουμε τις υπηρεσίες των εταιρειών τηλεπικοινωνιών, ανοίγοντας ταυτόχρονα νέους δρόμους για τη μελέτη της ιδιωτικότητας και των ορίων μεταξύ πραγματικού και συνθετικού στον ψηφιακό κόσμο.

1.2 Περιγραφή του Συνόλου Δεδομένων

Το σύνολο δεδομένων SMS Call Internet του Μιλάνου έχει διαμορφωθεί ειδικά για τη μελέτη της τηλεπικοινωνιακής δραστηριότητας σε αστικό περιβάλλον. Προέρχεται από ανωνυμοποιημένα Call Detail Records (CDRs) του δικτύου της Telecom Italia και καταγράφει κάθε ενέργεια κινητής τηλεφωνίας, όπως κλήσεις, SMS και χρήση διαδικτύου, σε διαστήματα δέκα λεπτών, στην ευρύτερη περιοχή του Μιλάνου και στην επαρχία Τρεντίνο, κατά τη διάρκεια του Νοεμβρίου 2013. Χάρη στη δομή του παρέχει πολύτιμες πληροφορίες για τη χωρική και χρονική κατανομή της τηλεπικοινωνιακής δραστηριότητας, διασφαλίζοντας ταυτόχρονα την προστασία της ιδιωτικότητας των χρηστών, καθώς δεν περιλαμβάνει προσωπικά δεδομένα.

Η γεωγραφική ανάλυση των δεδομένων στηρίζεται σε ένα πλέγμα που χωρίζει την περιοχή του Μιλάνου σε χίλια τετράγωνα, καθένα από τα οποία με διαστάσεις περίπου 235 x 235 μέτρα, βασισμένο στο γεωγραφικό σύστημα αναφοράς WGS84 (EPSG:4326). Κάθε εγγραφή περιλαμβάνει ένα μοναδικό αναγνωριστικό κελιού (CellID) και τον σχετικό κωδικό περιοχής (Country Code) μαζί με τη χρονική σήμανση και τον τύπο της τηλεπικοινωνιακής δραστηριότητας. Επιπλέον, κάθε φορά που ένας χρήστης πραγματοποιεί μία ενέργεια, καταγράφεται και ο ραδιοφωνικός σταθμός της βάσης που διαχειρίστηκε τη σύνδεση, προσφέροντας έτσι μία πιο λεπτομερή απεικόνιση της κινητικότητας και της ζήτησης επικοινωνιακών υπηρεσιών σε όλο το αστικό τοπίο.

Η συγκεκριμένη δομή των δεδομένων επιτρέπει την αναλυτική μελέτη των προτύπων χρήσης κινητής τηλεφωνίας σε πραγματικές συνθήκες, καθιστώντας το σύνολο δεδομένων αυτό, ιδανικό για τους στόχους της παρούσας εργασίας. Μέσω

της χρονικά και χωρικά λεπτομερούς καταγραφής των τηλεπικοινωνιακών ενεργειών, δίνεται η ευκαιρία να εκπαιδευτεί το γενετικό μοντέλο στη μάθηση της στατιστικής κατανομής που χαρακτηρίζει τη δραστηριότητα μιας ημέρας, εξασφαλίζοντας έτσι ότι τα συνθετικά δείγματα που παράγονται αντανακλούν με ακρίβεια τα πραγματικά χαρακτηριστικά της τηλεπικοινωνιακής κίνησης.

1.3 Οργάνωση και Μεθοδολογία της Εργασίας

Η παρούσα εργασία σχεδιάστηκε και υλοποιήθηκε με σκοπό να προσφέρει μια ολοκληρωμένη, συστηματική και σε βάθος ανάλυση της γενετικής μοντελοποίησης τηλεπικοινωνιακών δεδομένων με τη χρήση του προηγμένου μοντέλου Wasserstein GAN με Gradient Penalty (WGAN-GP). Η δομή και η μεθοδολογία που ακολουθούνται συνδυάζουν τη θεωρητική διερεύνηση με την πειραματική εφαρμογή, προσφέροντας σαφήνεια τόσο στη θεμελίωση όσο και στη διαδικασία και τα τελικά αποτελέσματα.

Στην αρχή πραγματοποιείται μία εκτενής επισκόπηση των θεμελιωδών εννοιών που διέπουν τη γενετική μοντελοποίηση, με ιδιαίτερη έμφαση στη λειτουργία και τα πλεονεκτήματα των Generative Adversarial Networks. Η ανάλυση αυτή οδηγεί φυσικά στην εμβάθυνση στο WGAN-GP, ως τη βέλτιστη τεχνική για την παραγωγή ρεαλιστικών συνθετικών δεδομένων σε πολύπλοκα, πραγματικά σενάρια. Στο θεωρητικό αυτό πλαίσιο, παρουσιάζονται αναλυτικά τα μαθηματικά θεμέλια, οι αρχές εκπαίδευσης και η αιτιολόγηση της επιλογής της συγκεκριμένης αρχιτεκτονικής.

Ακολουθεί η συστηματική παρουσίαση της διαδικασίας συλλογής και προεπεξεργασίας του συνόλου τηλεπικοινωνιακών δεδομένων. Αναλύονται διεξοδικά τα βήματα εντοπισμού και διαχείρισης ελλিপών ή προβληματικών τιμών, η επιλογή και εφαρμογή κατάλληλων τεχνικών κανονικοποίησης, καθώς και η διενέργεια στατιστικής ανάλυσης. Οι διαδικασίες αυτές διασφαλίζουν ότι το τελικό σύνολο δεδομένων είναι κατάλληλα διαμορφωμένο και βέλτιστα προετοιμασμένο για την εκπαίδευση του WGAN-GP.

Στη συνέχεια, η ανάλυση εστιάζει στην πρακτική υλοποίηση της αρχιτεκτονικής WGAN-GP, περιγράφοντας αναλυτικά τη δομή της γεννήτριας και του κριτή, την επιλογή και ρύθμιση των υπερπαραμέτρων, καθώς και τη μεθοδολογία εκπαίδευσης του μοντέλου. Ιδιαίτερη έμφαση δίνεται στις τεχνικές σταθεροποίησης της εκπαίδευσης, όπως η εφαρμογή του gradient penalty, καθώς και στη διαδικασία εναλλασσόμενης βελτιστοποίησης των δύο δικτύων, που αποτελεί τη θεμελιώδη αρχή της αντιπαραθετικής εκμάθησης. Επιπλέον, πραγματοποιείται συστηματική παρακολούθηση των κρίσιμων μετρικών ποιότητας και ποικιλίας σε κάθε στάδιο, ενώ τα αποτελέσματα παρουσιάζονται και ερμηνεύονται. Με τον τρόπο αυτό, αξιολογείται σε βάθος η ικανότητα του προτεινόμενου μοντέλου να παράγει συνθετικά δεδομένα που όχι μόνο προσεγγίζουν τα πραγματικά ως προς τα βασικά χαρακτηριστικά, αλλά διατηρούν και την απαραίτητη ποικιλία.

Η εργασία ολοκληρώνεται με τη συζήτηση των προοπτικών και των εφαρμογών της γενετικής μοντελοποίησης συνθετικών τηλεπικοινωνιακών δεδομένων. Ιδιαίτερη έμφαση δίνεται στη διασφάλιση της ιδιωτικότητας, στην ενίσχυση της διαθεσιμότητας δεδομένων για ερευνητικούς σκοπούς, και στη δυνατότητα χρήσης των συνθετικών δεδομένων σε σενάρια κυβερνοασφάλειας και ανάλυσης τηλεπικοινωνιακής δραστηριότητας.

Η εργασία είναι οργανωμένη στα εξής κύρια κεφάλαια:

- **Κεφάλαιο 1:** Εισαγωγή στη γενετική μοντελοποίηση, σκοπός, κίνητρο, περιγραφή δεδομένων και μεθοδολογία.
- **Κεφάλαιο 2:** Θεωρητική ανάλυση, αρχιτεκτονική και μαθηματική θεμελίωση των GAN, WGAN και WGAN-GP.
- **Κεφάλαιο 3:** Προεπεξεργασία δεδομένων και λεπτομερής υλοποίηση του προτεινόμενου μοντέλου.
- **Κεφάλαιο 4:** Πειραματική αξιολόγηση, ανάλυση μετρικών και εκτενής σχολιασμός αποτελεσμάτων.
- **Κεφάλαιο 5:** Συμπεράσματα, προτάσεις για μελλοντική έρευνα και εφαρμογές των συνθετικών δεδομένων στην πράξη.

Η συγκεκριμένη οργάνωση διασφαλίζει τη μεθοδική μετάβαση από τη θεωρητική τεκμηρίωση και τη μαθηματική θεμελίωση, στη μεθοδολογία υλοποίησης και, τελικά, στην ουσιαστική αξιολόγηση των αποτελεσμάτων και των δυνατοτήτων της γενετικής μοντελοποίησης στην πράξη. Με τον τρόπο αυτό, η εργασία λειτουργεί τόσο ως επιστημονικό εγχειρίδιο αναφοράς όσο και ως πρακτικός οδηγός για την ανάπτυξη, την αξιολόγηση και την εφαρμογή του WGAN-GP σε δεδομένα τηλεπικοινωνιακής δραστηριότητας.

2. Κατανόηση

2.1 Αρχιτεκτονική των GANs

Η αρχιτεκτονική των GANs βασίζεται σε μια καινοτόμο ιδέα, σύμφωνα με την οποία δύο νευρωνικά δίκτυα, η γεννήτρια (Generator) και ο διαχωριστής (Discriminator), τοποθετούνται σε ανταγωνιστική διάταξη, λειτουργώντας ως αντίπαλα μέρη σε ένα παιχνίδι μηδενικού αθροίσματος. Η γεννήτρια αναλαμβάνει τον ρόλο του «παραχαράκτη», αποστολή της οποίας είναι η παραγωγή δειγμάτων που μιμούνται σε τέτοιο βαθμό τα αληθινά δεδομένα, ώστε να καθίσταται δύσκολο ακόμα και για έναν ειδικό να τα διακρίνει. Αντίθετα, ο διαχωριστής λειτουργεί ως «ειδικός ελεγκτής», επιφορτισμένος με το καθήκον να διακρίνει με ακρίβεια αν ένα δείγμα προέρχεται από τα πραγματικά δεδομένα ή αν έχει παραχθεί τεχνητά από τη γεννήτρια.

Η δυναμική αυτή αλληλεπίδραση αποτελεί τον πυρήνα της εκπαίδευσης ενός GAN και οδηγεί σε μια εξελικτική διαδικασία βελτιστοποίησης και των δύο δικτύων. Καθώς ο διαχωριστής βελτιώνει συνεχώς την ικανότητά του να εντοπίζει πλαστά δείγματα, η γεννήτρια εξαναγκάζεται να τελειοποιεί τη στρατηγική της, προσπαθώντας να παραγάγει όλο και πιο πειστικά και ρεαλιστικά δεδομένα. Το αποτέλεσμα είναι ένα σύστημα όπου κάθε αποτυχία της γεννήτριας μετατρέπεται


σε ερέθισμα για περαιτέρω βελτίωση, ενώ κάθε επιτυχία του διαχωριστή αυξάνει το επίπεδο πρόκλησης, ανεβάζοντας τον πήχη της ακρίβειας.

Ένα από τα πλέον ενδιαφέροντα χαρακτηριστικά αυτής της αρχιτεκτονικής είναι ότι ο ανταγωνισμός μεταξύ γεννήτριας και διαχωριστή τείνει να οδηγεί σε μία κατάσταση ισορροπίας. Σε αυτή την ισορροπία, η γεννήτρια παράγει δείγματα τόσο ρεαλιστικά που ο διαχωριστής αδυνατεί να τα ξεχωρίσει με βεβαιότητα από τα πραγματικά. Η αλληλεπίδραση αυτή συχνά παρομοιάζεται με έναν ταλαντούχο παραχαράκτη που επιχειρεί να περάσει πλαστά χαρτονομίσματα σε μια τράπεζα, προσπαθώντας να ξεγελάσει έναν εξαιρετικά έμπειρο ελεγκτή, ο οποίος όμως βελτιώνεται διαρκώς στην ανίχνευση των πλαστών.

Η διαρκής αυτή μάχη οδηγεί τελικά σε συνεχή αμοιβαία βελτίωση και των δύο δικτύων. Ο παραχαράκτης (γεννήτρια) αναγκάζεται να βελτιώνει διαρκώς την τεχνική του, παράγοντας ολοένα και πιο αληθοφανή δείγματα, με στόχο αυτά να γίνουν πρακτικά αδιάκριτα από τα γνήσια. Επομένως, μέσα από αυτή τη διαδικασία, το σύστημα καταλήγει σε ένα λειτουργικό γενετικό μοντέλο, ικανό να προσομοιώνει με υψηλή πιστότητα τα χαρακτηριστικά των πραγματικών δεδομένων. Αυτή η συνεχής αλληλεπίδραση και βελτίωση αποτελεί το θεμέλιο πάνω στο οποίο βασίζεται η επιτυχία των GANs.

2.2 Μαθηματική Θεμελίωση των GANs


Η μαθηματική θεμελίωση των GANs ξεκινά από την ανάγκη να προσεγγιστεί η άγνωστη κατανομή δεδομένων, την οποία ονομάζουμε $P(X)$, όπου X είναι ο χώρος όλων των πιθανών δεδομένων. Η διαδικασία αυτή απαιτεί από το μοντέλο να μάθει πώς πραγματικά παράγονται τα δεδομένα, ώστε να μπορεί να δημιουργήσει νέα, εξίσου πειστικά δείγματα. Σε αυτό το σημείο υπεισέρχεται η χρήση παραμετρικών μοντέλων, τα οποία ορίζονται από ένα σύνολο παραμέτρων θ , με στόχο να εκτιμήσουν όσο το δυνατόν καλύτερα την αληθινή κατανομή.



Σχήμα 1.1: Στόχος της Γενετικής Μοντελοποίησης — Εκμάθηση της Παραμετρικής Κατανομής $P_\theta(X)$ που Προσεγγίζει την Άγνωστη Αληθινή Κατανομή $P(X)$ των Δεδομένων.


Η βασική πρόκληση βρίσκεται στο γεγονός ότι η πραγματική διαδικασία δημιουργίας των δεδομένων είναι άγνωστη και, στις περισσότερες περιπτώσεις, εξαιρετικά πολύπλοκη. Αυτό σημαίνει ότι δεν μπορούμε να γνωρίζουμε ή να υπολογίσουμε άμεσα το συνολικό άθροισμα ή το ολοκλήρωμα που απαιτείται για να γίνει κανονικοποίηση της κατανομής. Το πρόβλημα αυτό επιτείνεται όσο αυξάνεται η διαστατικότητα των δεδομένων, καθιστώντας τον υπολογισμό του παράγοντα κανονικοποίησης πρακτικά αδύνατο. Με σκοπό να παρακάμψουν αυτό το εμπόδιο, τα GANs χρησιμοποιούν την κρυφή μεταβλητή θορύβου Z , που ακολουθεί γνωστή κατανομή (συνήθως κανονική). Η γεννήτρια μαθαίνει να

μετατρέπει σημεία από τον χώρο του θορύβου σε σημεία του χώρου των δεδομένων, με τέτοιο τρόπο ώστε τα τελικά παραγόμενα δείγματα να μην διαφέρουν στατιστικά από τα πραγματικά.




Σχήμα 1.2: Τα GANs μαθαίνουν να μετασχηματίζουν θόρυβο από μια γνωστή κατανομή $P_z(Z)$ σε δεδομένα που ακολουθούν την επιθυμητή κατανομή $P_\theta(X)$, μέσω της διαδικασίας μάθησης της γεννήτριας.

Πιο συγκεκριμένα, η γεννήτρια χαρτογραφεί την κατανομή θορύβου στον χώρο της κρυφής μεταβλητής σε μια κατανομή P_G στον χώρο των δεδομένων, η οποία θέλουμε να ευθυγραμμιστεί όσο το δυνατόν περισσότερο με την στοχευμένη κατανομή $P(X)$. Δηλαδή, επιδιώκουμε τα παραγόμενα δείγματα να είναι αδιάκριτα από τα πραγματικά. Από την άλλη πλευρά, ο διαχωριστής D έχει την αποστολή να ξεχωρίσει τα πραγματικά δείγματα από τα παραγόμενα, λαμβάνοντας ως είσοδο το X και παράγοντας μια τιμή μεταξύ 0 και 1, που ερμηνεύεται ως η πιθανότητα το X να είναι πραγματικό. Έτσι, χωρίς να απαιτείται άμεση εκτίμηση της αληθινής κατανομής, το GAN καταφέρνει να «αντιγράψει» τα βασικά χαρακτηριστικά των δεδομένων μέσω της δυναμικής αλληλεπίδρασης γεννήτριας και διαχωριστή.



Σχήμα 1.3: Ο Ρόλος της Γεννήτριας (Παραχαράκτη) στα GANs — Χαρτογράφηση της Κατανομής Θορύβου $P_z(Z)$ στην Παραγόμενη Κατανομή $P_G(X)$ με Στόχο την Προσέγγιση της Αληθινής Κατανομής $P(X)$



Σχήμα 1.4: Ο Ρόλος του Διαχωριστή (Τραπεζικού Υπαλλήλου) στα GANs — Διάκριση Μεταξύ Πραγματικών και Παραγόμενων Δειγμάτων

Συνολικά, η θεμελιώδης μαθηματική καινοτομία των GANs είναι η δυνατότητα εκμάθησης πολύπλοκων κατανομών χωρίς την ανάγκη πλήρους γνώσης της μορφής τους ή του όρου κανονικοποίησης. Αυτό επιτυγχάνεται μέσω της χρήσης αντιπαραθετικών νευρωνικών δικτύων και της στρατηγικής εκπαίδευσης που αυτά προσφέρουν.

2.3 Αρχιτεκτονική WGAN

Όπως παρατηρείται, παρά τη θεωρητική δυνατότητα των GANs να μάθουν την πραγματική κατανομή των δεδομένων, στην πράξη η εκπαίδευσή τους συχνά συνοδεύεται από σημαντικές προκλήσεις ως προς τη σταθερότητα. Συγκεκριμένα, ο διαχωριστής μπορεί να γίνει υπερβολικά ισχυρός, εμποδίζοντας τη βελτίωση της γεννήτριας, ή η γεννήτρια μπορεί να εμφανίσει mode collapse, παράγοντας περιορισμένη ποικιλία δειγμάτων. Επιπλέον, η διαδικασία εκπαίδευσης των GANs συχνά δεν συγκλίνει ομαλά, με αποτέλεσμα τη δημιουργία γεννητριών που παράγουν μη ρεαλιστικές εξόδους ή παρουσιάζουν ασταθή συμπεριφορά.

Για να αντιμετωπιστούν αυτά τα προβλήματα, αναπτύχθηκε η αρχιτεκτονική του Wasserstein GAN (WGAN), η οποία εισάγει μια σημαντική διαφοροποίηση σε σχέση με τα παραδοσιακά GANs και συμβάλλει ουσιαστικά στη βελτίωση της σταθερότητας και της ποιότητας της εκπαίδευσης. Το WGAN διατηρεί τη διπλή δομή της γεννήτριας και του διαχωριστή, αλλά ταυτόχρονα τροποποιεί τη λειτουργία του διαχωριστή: στη θέση του εισάγεται ο κριτής, ο οποίος δεν εκτελεί απλώς δυαδική διάκριση (REAL/FAKE), αλλά βαθμολογεί τα δείγματα με πραγματικές τιμές που αντανakλούν το πόσο κοντά βρίσκονται στην κατανομή των πραγματικών δεδομένων.



Σχήμα 1.5: Συγκριτική απεικόνιση της λειτουργίας διαχωριστή (Discriminator) και κριτή (Critic) στα GAN και WGAN, μέσα από το παράδειγμα της παραχάραξης χαρτονομισμάτων

Αυτή η νέα προσέγγιση αλλάζει ριζικά τη φύση της ανάδρασης που λαμβάνει η γεννήτρια κατά την εκπαίδευση. Ενώ στα κλασικά GANs η γεννήτρια ενημερώνεται με βάση μια δυαδική εκτίμηση, στο WGAN λαμβάνει μια πιο αναλυτική και πλούσια σε πληροφορία βαθμολογία, που της υποδεικνύει πόσο μακριά βρίσκεται το κάθε δείγμα από το να θεωρηθεί αληθινό. Έτσι, η γεννήτρια έχει τη δυνατότητα να βελτιώνεται πιο σταδιακά και μεθοδικά, αποφεύγοντας τα συνηθισμένα αδιέξοδα της εκπαίδευσης.

2.4 Μαθηματική Θεμελίωση WGAN

Η καρδιά της μαθηματικής θεμελίωσης του WGAN βρίσκεται στη χρήση της απόστασης Wasserstein ως συνάρτησης απώλειας. Η απόσταση αυτή μετρά το ελάχιστο έργο που απαιτείται για να μετακινηθεί η κατανομή των παραγόμενων δεδομένων στη θέση της κατανομής των πραγματικών. Η υιοθέτηση αυτής της μετρικής προσφέρει σταθερότερες και πιο χρήσιμες κλίσεις κατά τη διαδικασία εκπαίδευσης, επιτρέποντας στη γεννήτρια να προσεγγίζει πιο αποτελεσματικά την επιθυμητή κατανομή. Σε αντίθεση με τη Jensen-Shannon Divergence που χρησιμοποιούν τα κλασικά GANs, η Wasserstein απόσταση προσφέρει πιο ομαλές και σταθερές κλίσεις, ακόμη και όταν οι δύο κατανομές δεν επικαλύπτονται καθόλου. Έτσι, η γεννήτρια λαμβάνει διαρκώς πληροφορία σχετικά με την κατεύθυνση βελτίωσης, ακόμη και όταν τα παραγόμενα δείγματα απέχουν σημαντικά από τα πραγματικά δεδομένα.

Η υλοποίηση της Wasserstein απόστασης στα WGANs βασίζεται στην αρχή της δυϊκότητας, που επιτρέπει τον υπολογισμό του supremum όλων των 1-Lipschitz συναρτήσεων που διαχωρίζουν τις δύο κατανομές. Πρακτικά, ο κριτής εκπαιδεύεται να προσεγγίζει μια τέτοια 1-Lipschitz συνάρτηση, μεγιστοποιώντας τη διαφορά των μέσων τιμών που δίνει σε πραγματικά και συνθετικά δείγματα. Έτσι, αντί να προσπαθούμε να εκτιμήσουμε όλες τις πιθανές

αντιστοιχίσεις μεταξύ των δύο κατανομών (κάτι που είναι υπολογιστικά αδύνατο), το πρόβλημα μεταφέρεται σε ένα πεδίο όπου η εκμάθηση είναι πιο εφικτή.

$$W(\mathbb{P}_r, \mathbb{P}_g) = \sup_{\|f\|_L \leq 1} \mathbb{E}_{x \sim \mathbb{P}_r} [f(x)] - \mathbb{E}_{x \sim \mathbb{P}_g} [f(x)]$$

Μαθηματικός Τύπος 1.1: Δυσκολία Kantorovich-Rubinstein για την Απόσταση Wasserstein

Αρχικά, η εφαρμογή του περιορισμού 1-Lipschitz γινόταν μέσω weight clipping, δηλαδή με περιορισμό των βαρών του κριτή σε συγκεκριμένο εύρος. Ωστόσο, αυτή η μέθοδος αποδείχθηκε προβληματική, καθώς περιορίζει την εκφραστικότητα του δικτύου και μπορούσε να οδηγήσει σε vanishing ή exploding gradients. Ως αποτέλεσμα, η δύναμη της Wasserstein απόστασης δεν αξιοποιούνταν πλήρως, επιβάλλοντας έτσι νέους περιορισμούς στη διαδικασία μάθησης του μοντέλου.

2.5 Αρχιτεκτονική WGAN-GP

Η αρχιτεκτονική του WGAN-GP (Wasserstein GAN with Gradient Penalty) αποτελεί τη φυσική εξέλιξη του WGAN, σχεδιασμένη με τέτοιο τρόπο ώστε να ξεπεράσει τα μειονεκτήματα του weight clipping που χρησιμοποιήθηκε στο αρχικό WGAN. Όπως προτάθηκε από τους Gulrajani και συνεργάτες (2017), το WGAN-GP εισάγει έναν νέο όρο απώλειας, την ποινή κλίσης (gradient penalty), ο οποίος διασφαλίζει τη διατήρηση της 1-Lipschitz ιδιότητας του κριτή με πιο ομαλό και φυσικό τρόπο. Αυτή η προσέγγιση καθιστά την εκπαίδευση του δικτύου σημαντικά πιο σταθερή και αξιόπιστη, ακόμη και όταν το σύνολο δεδομένων είναι πολύπλοκο ή περιέχει θόρυβο.

Στο WGAN-GP, η γεννήτρια εξακολουθεί να λαμβάνει ως είσοδο δείγματα από μια γνωστή κατανομή θορύβου και να παράγει συνθετικά δεδομένα, ενώ ο κριτής αξιολογεί το πόσο ρεαλιστικά είναι αυτά τα δείγματα σε σχέση με τα πραγματικά δεδομένα. Η ειδοποιός διαφορά σε σχέση με το κλασικό WGAN είναι ότι η 1-Lipschitz συνθήκη δεν επιβάλλεται μέσω απότομου περιορισμού των βαρών (weight clipping), αλλά μέσω της προσθήκης ενός όρου ποινής στη συνάρτηση κόστους. Αυτός ο όρος ενεργοποιείται κάθε φορά που η νόρμα της παραγώγου της εξόδου του κριτή αποκλίνει από τη μονάδα, εξασφαλίζοντας έτσι ότι ο κριτής παραμένει εντός των επιθυμητών ορίων εκφραστικότητας και λειτουργικότητας.

Η εισαγωγή της ποινής κλίσης λειτουργεί ως ισχυρός μηχανισμός κανονικοποίησης, κρατώντας τον κριτή σε ένα υγιές και παραγωγικό καθεστώς μάθησης. Ως αποτέλεσμα, η εκπαίδευση γίνεται ιδιαίτερα σταθερή: αποφεύγονται τόσο τα φαινόμενα exploding gradients όσο και τα vanishing gradients, ενώ η ποιότητα των παραγόμενων δειγμάτων βελτιώνεται σημαντικά. Ο κριτής μπορεί πλέον να μαθαίνει πολύπλοκες, μη γραμμικές συναρτήσεις χωρίς να περιορίζεται τεχνητά, γεγονός που μεταφράζεται σε καλύτερη προσέγγιση της κατανομής των πραγματικών δεδομένων.

Μια σημαντική λεπτομέρεια που προκύπτει από την πρακτική εφαρμογή του WGAN-GP είναι η επιλογή του συντελεστή βαρύτητας λ (lambda) για το penalty.

Τυπικά, τιμή $\lambda = 10$ θεωρείται κατάλληλη, καθώς ισορροπεί ιδανικά την επιβολή του περιορισμού Lipschitz χωρίς να υπερκαλύπτει το συνολικό loss. Η προσεκτική επιλογή αυτής της παραμέτρου συμβάλλει καθοριστικά στη σταθερότητα της εκπαίδευσης και στην τελική ποιότητα των συνθετικών δειγμάτων που παράγει το μοντέλο.

2.6 Μαθηματική Θεμελίωση WGAN-GP

Η μαθηματική θεμελίωση του WGAN-GP βασίζεται στην ανάγκη διατήρησης της 1-Lipschitz ιδιότητας στον κριτή, η οποία είναι κρίσιμη για τη σωστή εκτίμηση της απόστασης Wasserstein. Ο πιο αποτελεσματικός τρόπος για να διασφαλιστεί αυτή η ιδιότητα είναι η εισαγωγή ενός όρου ποινής στη συνάρτηση απώλειας, κάθε φορά που η νόρμα του διανύσματος κλίσης της εξόδου του κριτή αποκλίνει από τη μονάδα. Έτσι ώστε ο ίδιος να παραμένει 1-Lipschitz κατά τη διάρκεια της εκπαίδευσης με φυσικό τρόπο, χωρίς να απαιτείται η επιβολή απότομων ή τεχνητών περιορισμών στα βάρη, όπως συμβαίνει στην περίπτωση του weight clipping. Αυτή η προσέγγιση διατηρεί την εκφραστικότητα και τη μαθησιακή ικανότητα του δικτύου, ενώ αποφεύγει τις αρνητικές συνέπειες των τεχνικών περιορισμού.

Ένα σημαντικό πλεονέκτημα του gradient penalty αφορά τη συμπεριφορά των βαρών του δικτύου. Ενώ με το weight clipping τα βάρη τείνουν να κολλούν στα άκρα του επιτρεπτού διαστήματος $\pm c$, περιορίζοντας τον κριτή σχεδόν σε δυαδικές αποφάσεις και μειώνοντας δραστικά την εκφραστικότητά του, με το gradient penalty τα βάρη κατανέμονται ομαλά γύρω από το μηδέν. Αυτό επιτρέπει στο νευρωνικό δίκτυο να αξιοποιεί πλήρως τη χωρητικότητά του, μαθαίνοντας ακόμα πιο πλούσιες και πολύπλοκες συναρτήσεις, με αποτέλεσμα την παραγωγή πιο ρεαλιστικών και ακριβών συνθετικών δεδομένων.

Επιπλέον, η εφαρμογή του όρου ποινής γίνεται σε τυχαία σημεία που προκύπτουν ως ενδιάμεσες τοποθεσίες μεταξύ πραγματικών και παραγόμενων δειγμάτων. Για κάθε τέτοιο σημείο, υπολογίζεται η νόρμα της παραγώγου της εξόδου του κριτή ως προς την είσοδο και η απόκλιση της από τη μονάδα. Η συνολική συνάρτηση απώλειας προκύπτει προσθέτοντας τον όρο ποινής στη βασική Wasserstein loss, με αποτέλεσμα ο κριτής να διατηρεί σταθερή και ομαλή συμπεριφορά ακόμα και σε περιοχές όπου τα πραγματικά και τα συνθετικά δείγματα διαφέρουν σημαντικά. Αυτό διασφαλίζει καλύτερη καθοδήγηση για τη γεννήτρια και πιο σταθερή σύγκλιση κατά την εκπαίδευση.

$$\mathcal{L} = \underbrace{\mathbb{E}_{\tilde{\mathbf{x}} \sim \mathbb{P}_g} [f(\tilde{\mathbf{x}})] - \mathbb{E}_{\mathbf{x} \sim \mathbb{P}_r} [f(\mathbf{x})]}_{\text{Αρχική Wasserstein Loss (διαφορά μέσων εξόδων μεταξύ παραγόμενων και πραγματικών δειγμάτων)}} + \lambda \underbrace{\mathbb{E}_{\hat{\mathbf{x}} \sim \mathbb{P}_{\hat{\mathbf{x}}}} [(\|\nabla_{\hat{\mathbf{x}}} f(\hat{\mathbf{x}})\|_2 - 1)^2]}_{\substack{\text{πόσο απέχει το μέτρο του gradient από το 1.} \\ \text{Όρος Gradient Penalty πάνω στη νόρμα της κλίσης.}}}$$

Μαθηματικός Τύπος 1.2: Εφαρμογή Ποινής Κλίσης (Gradient Penalty) στη Συνάρτηση Απώλειας του WGAN-GP για την Ικανοποίηση της Συνθήκης 1-Lipschitz

Η μαθηματική θεμελίωση του gradient penalty βασίζεται στη θεωρία των Lipschitz συναρτήσεων, καθώς και στις αρχές της βελτιστοποίησης και της στατιστικής μάθησης. Αυτό προσδίδει στο συγκεκριμένο εργαλείο τόσο θεωρητική αρτιότητα όσο και πρακτική αποτελεσματικότητα στη γενετική μοντελοποίηση. Η επιτυχία του WGAN-GP αποδίδεται στον συνδυασμό θεωρητικής αυστηρότητας και πρακτικής αξιοπιστίας, καθιστώντας το πλαίσιο αυτό σημείο αναφοράς για την παραγωγή συνθετικών δεδομένων με χρήση νευρωνικών δικτύων.


3. Προετοιμασία Δεδομένων και Υλοποίηση Μοντέλου

3.1 Προεπεξεργασία Δεδομένων

Η προεπεξεργασία του συνόλου δεδομένων ξεκίνησε με την τμηματική φόρτωση των δεδομένων από το αρχείο CSV σε μεγάλα τμήματα, ώστε να διαχειριστεί αποτελεσματικά τον όγκο των 1,89 εκατομμυρίων εγγραφών. Κατά τη φόρτωση, η στήλη datetime μετατράπηκε σε τύπο ημερομηνίας, ενώ οι βασικές αναγνωριστικές στήλες CellID και countrycode διατηρήθηκαν χωρίς καμία τροποποίηση. Στη συνέχεια, πραγματοποιήθηκε λεπτομερής έλεγχος για ελλείψεις τιμές. Οι στήλες datetime, CellID και countrycode, οι οποίες είναι κρίσιμες για τη χρονολογική και γεωγραφική ταυτοποίηση κάθε εγγραφής, δεν εμφάνιζαν καμία έλλειψη. Αντίθετα, στις στήλες τηλεπικοινωνιακής δραστηριότητας (smsin, smsout, callin, callout, internet) παρατηρήθηκαν εκτεταμένες ελλείψεις (έως και 1,4 εκατομμύρια NaN ανά στήλη), οι οποίες αντικαταστάθηκαν με μηδενικά, δεδομένου ότι το μηδέν αντιπροσωπεύει την απουσία δραστηριότητας και αποτελεί ουσιώδες μέρος της κατανομής των δεδομένων. Ακολούθησε επιλογή των πέντε τηλεπικοινωνιακών χαρακτηριστικών ως είσοδος για το GAN, ενώ αφαιρέθηκε το ελάχιστο ποσοστό εγγραφών (περίπου 0,1%) στις οποίες όλες οι τιμές ήταν μηδενικές, ώστε το μοντέλο να εστιάσει στην εκμάθηση ενεργών μοτίβων χρήσης και προστέθηκε στη συνέχεια ώστε να ληφθεί υπόψιν.

Η στατιστική ανάλυση των επιλεγμένων χαρακτηριστικών έδειξε ότι το 25ο, 50ο και 75ο ποσοστημόριο είναι ίσο με μηδέν, γεγονός που σημαίνει ότι τουλάχιστον το 75% των εγγραφών δεν καταγράφει καμία δραστηριότητα σε SMS, κλήσεις ή χρήση διαδικτύου. Αυτή η κυριαρχία των μηδενικών τιμών είναι χαρακτηριστική των τηλεπικοινωνιακών δεδομένων και διατηρήθηκε, καθώς αντανακλά πραγματικές περιόδους χωρίς χρήση υπηρεσίας. Για την ομαλοποίηση των μεταβλητών και την αποτροπή προβλημάτων κατά την εκπαίδευση του μοντέλου, εφαρμόστηκε κανονικοποίηση Z-score (μέση τιμή 0, τυπική απόκλιση 1). Η διαδικασία αυτή διατήρησε τη μεγάλη μάζα των μηδενικών τιμών, δημιουργώντας ένα έντονο spike στη νέα κατανομή, ενώ οι σπάνιες θετικές τιμές διασπείρονται δεξιά του spike και γίνονται ευδιάκριτες. Έτσι, το μοντέλο μπορεί να διακρίνει ξεκάθαρα την απουσία από την παρουσία δραστηριότητας, γεγονός που

συμβάλλει στη σταθερότητα και την αποτελεσματικότητα της εκπαίδευσης.



Σχήμα 1.6: Οπτική αποτύπωση των συσχετίσεων και της διασποράς των μεταβλητών τηλεπικοινωνιακής δραστηριότητας

Η παραπάνω εικόνα αναδεικνύεται και οπτικά μέσω διαγραμμάτων διασποράς, pair plots και heatmap. Το heatmap αποκαλύπτει ισχυρές θετικές συσχετίσεις μεταξύ των μεταβλητών SMS in–SMS out (0.58) και call in–call out (0.39), γεγονός που υποδηλώνει πως οι χρήστες που στέλνουν ή λαμβάνουν SMS ή κλήσεις, κατά κανόνα, κάνουν και το αντίστροφο. Τα pair plots επιβεβαιώνουν το υψηλό ποσοστό μηδενικών, καθώς η πλειονότητα των εγγραφών αντιστοιχεί σε χρονικές περιόδους χωρίς καμία χρήση υπηρεσιών. Με αυτά τα χαρακτηριστικά, το WGAN-GP παράγει συνθετικά δεδομένα ροής κυκλοφορίας που διατηρούν με ακρίβεια τις στατιστικές ιδιότητες του αρχικού συνόλου, αναπαράγοντας τόσο τα διαστήματα χαμηλής δραστηριότητας όσο και τις περιόδους έντονης χρήσης.

3.2 Υλοποίηση Μοντέλου

Το μοντέλο που υλοποιήθηκε βασίζεται στη συνεργασία δύο διακριτών νευρωνικών δικτύων: της γεννήτριας (Generator) και του κριτή (Critic). Αυτή η δυαδική αρχιτεκτονική αποτελεί τη θεμέλια λίθο των Wasserstein GANs με Gradient Penalty (WGAN-GP) και αξιοποιεί τον ανταγωνισμό μεταξύ των δύο δικτύων για να παραχθούν συνθετικά δεδομένα υψηλής ποιότητας.

Η γεννήτρια υλοποιήθηκε ως ένα πολυεπίπεδο νευρωνικό δίκτυο που αποτελείται από διαδοχικά πλήρως συνδεδεμένα επίπεδα με 64, 128 και 32 νευρώνες, ακολουθώντας το μοτίβο expansion-compression, δηλαδή την προοδευτική διεύρυνση και εν συνεχεία συμπίεση του δικτύου πριν το τελικό επίπεδο. Αυτή η αρχιτεκτονική διευκολύνει τη σταδιακή μετατροπή του τυχαίου διανύσματος θορύβου σε συνθετικά δείγματα που αναπαριστούν πιστά την πολυπλοκότητα του πραγματικού συνόλου δεδομένων, ενώ παράλληλα περιορίζει τον κίνδυνο υπερπροσαρμογής. Σε κάθε ενδιάμεσο επίπεδο, μετά από κάθε Dense layer, εφαρμόζεται LayerNormalization, η οποία κανονικοποιεί κάθε δείγμα ανεξάρτητα, διατηρώντας σταθερά στατιστικά κατά μήκος όλων των νευρώνων του επιπέδου και διασφαλίζοντας τη σταθερότητα της εκπαίδευσης ακόμη και σε περιπτώσεις

μικρών ή ανισόρροπων batch. Η χρήση LayerNormalization αντί για BatchNormalization αποτελεί πλέον βέλτιστη πρακτική σε GANs για tabular δεδομένα, καθώς αποτρέπει τη διαρροή πληροφορίας μεταξύ των δειγμάτων ενός batch και περιορίζει το φαινόμενο της αστάθειας κατά την εκπαίδευση. Μετά από κάθε κανονικοποίηση εφαρμόζεται η συνάρτηση ενεργοποίησης ReLU, εισάγοντας μη γραμμικότητα και δίνοντας στο δίκτυο τη δυνατότητα να μάθει σύνθετες συσχετίσεις και αλληλεπιδράσεις στα δεδομένα. Το τελικό επίπεδο της γεννήτριας αποτελείται από 5 νευρώνες με γραμμική ενεργοποίηση, παρέχοντας ένα συνεχές διάνυσμα πέντε χαρακτηριστικών πλήρως συμβατό με τα normalized features του πραγματικού συνόλου δεδομένων. Όλες οι παράμετροι του δικτύου είναι trainable, διασφαλίζοντας τη μέγιστη ευελιξία και προσαρμοστικότητα κατά τη διαδικασία μάθησης.

Ο κριτής σχεδιάστηκε ώστε να πληροί τις απαιτήσεις του WGAN-GP και υλοποιήθηκε ως ένα πολυεπίπεδο νευρωνικό δίκτυο με τρία διαδοχικά πλήρως συνδεδεμένα επίπεδα των 128, 64 και 32 νευρώνων, στα οποία εφαρμόζεται η συνάρτηση ενεργοποίησης LeakyReLU με παράμετρο 0.2. Η επιλογή της LeakyReLU αντί της απλής ReLU διασφαλίζει ότι τα gradients παραμένουν ενεργά ακόμη και σε αρνητικές τιμές, ενισχύοντας τη ροή πληροφορίας και αποτρέποντας το φαινόμενο των «νεκρών» νευρώνων, μια κρίσιμη παράμετρος για τη σταθερότητα της εκπαίδευσης. Το τελικό επίπεδο του δικτύου περιλαμβάνει έναν νευρώνα χωρίς ενεργοποίηση, ο οποίος επιστρέφει το Wasserstein score: έναν πραγματικό αριθμό που ποσοτικοποιεί το βαθμό ομοιότητας κάθε δείγματος με την κατανομή των πραγματικών δεδομένων, σύμφωνα με το θεωρητικό πλαίσιο του Wasserstein GAN. Αξίζει να σημειωθεί ότι στη συγκεκριμένη αρχιτεκτονική δεν χρησιμοποιείται καμία μορφή κανονικοποίησης (BatchNormalization ή LayerNormalization), διότι οποιαδήποτε κανονικοποίηση σε επίπεδο batch θα εισήγαγε εξαρτήσεις μεταξύ των δειγμάτων, παραβιάζοντας τη συνθήκη 1-Lipschitz που είναι θεμελιώδης για την ορθή εφαρμογή του gradient penalty στο WGAN-GP. Τέλος, κατά τη φάση εκπαίδευσης της γεννήτριας, τα βάρη του κριτή διατηρούνται παγωμένα (non-trainable) και χρησιμοποιούνται αποκλειστικά για την αξιολόγηση της ποιότητας των παραγόμενων συνθετικών δειγμάτων, διασφαλίζοντας την ομαλή εναλλαγή ρόλων και την ισορροπία στον ανταγωνισμό μεταξύ των δύο δικτύων.

Συνοψίζοντας, η γεννήτρια μετασχηματίζει ένα τυχαίο διάνυσμα θορύβου σε ένα διάνυσμα πέντε χαρακτηριστικών μέσω μιας αλληλουχίας πλήρως συνδεδεμένων επιπέδων με 64, 128 και 32 νευρώνες, όπου κάθε επίπεδο (εκτός του τελευταίου) ακολουθείται από LayerNormalization και ενεργοποίηση ReLU. Αυτή η δομή εξασφαλίζει σταθερότητα στην εκπαίδευση και δυνατότητα εκμάθησης σύνθετων συσχετίσεων στα δεδομένα. Όλες οι παράμετροι της γεννήτριας είναι trainable, επιτρέποντας πλήρη βελτιστοποίηση του δικτύου σε κάθε βήμα εκπαίδευσης. Ο κριτής, από την άλλη, παράγει ένα ενιαίο Wasserstein score για κάθε εισερχόμενο δείγμα, χρησιμοποιώντας τρία διαδοχικά dense layers με 128, 64 και 32 νευρώνες και ενεργοποίηση LeakyReLU, χωρίς καμία μορφή normalization, διατηρώντας έτσι την ανεξαρτησία των δειγμάτων και τη συνθήκη 1-Lipschitz που απαιτεί το WGAN-GP. Αυτή η αρχιτεκτονική διασφαλίζει υψηλή σταθερότητα, γρήγορη

σύγκλιση κατά την εκπαίδευση και εξαιρετική ποιότητα στα παραγόμενα συνθετικά δεδομένα, καθιστώντας το σύστημα ιδιαίτερα αποτελεσματικό για το σκοπό της γενετικής μοντελοποίησης τηλεπικοινωνιακής δραστηριότητας.

3.3 Διαδικασία Εκπαίδευσης και Ρύθμιση Υπερπαραμέτρων

Η διαδικασία εκπαίδευσης του WGAN-GP βασίζεται σε μία προσεκτικά σχεδιασμένη αλληλουχία βημάτων που διασφαλίζει τη διαδοχική και ισορροπημένη βελτιστοποίηση της γεννήτριας και του κριτή. Σε κάθε επανάληψη, τα δύο δίκτυα λειτουργούν ανταγωνιστικά: η γεννήτρια, από τη μία, δημιουργεί συνθετικά δείγματα ξεκινώντας από ένα τυχαίο θόρυβο, κανονικής κατανομής, ενώ ο κριτής, από την άλλη, αξιολογεί κατά πόσο αυτά τα δείγματα μοιάζουν με τα πραγματικά δεδομένα του συνόλου εκπαίδευσης. Η όλη διαδικασία βασίζεται στην αρχιτεκτονική Wasserstein GAN με gradient penalty, διασφαλίζοντας σταθερότητα, αποφυγή φαινομένων exploding/vanishing gradients και υψηλή ποιότητα αλλά και ποικιλία των παραγόμενων δεδομένων.

Η εκπαίδευση ξεκινά με τη δημιουργία ενός `tf.data.Dataset` από το προεπεξεργασμένο σύνολο δεδομένων, το οποίο αναμιγνύεται τυχαία και διαχωρίζεται σε batches μεγέθους 128, προσφέροντας ομοιομορφία και διευκολύνοντας την εκμάθηση. Σε κάθε βήμα εκπαίδευσης του κριτή, ως είσοδος χρησιμοποιούνται τόσο πραγματικά δεδομένα όσο και συνθετικά δείγματα που έχουν παραχθεί από τη γεννήτρια. Ο κριτής παράγει βαθμολογίες για κάθε δείγμα, οι οποίες καθορίζουν τη συνεισφορά κάθε batch στη συνολική συνάρτηση απώλειας. Για τη διατήρηση της 1-Lipschitz συνθήκης, απαραίτητης για τη σωστή εκτίμηση της Wasserstein απόστασης, εφαρμόζεται το gradient penalty: σε κάθε batch δημιουργούνται ενδιάμεσα δείγματα μέσω γραμμικής παρεμβολής μεταξύ πραγματικών και συνθετικών δειγμάτων, με τυχαίο βάρος ϵ από ομοιόμορφη κατανομή $[0,1]$, και υπολογίζεται η νόρμα της παραγώγου της εξόδου του κριτή ως προς την είσοδο. Όταν η νόρμα αποκλίνει από τη μονάδα, προστίθεται όρος ποινής (penalty) με συντελεστή $\lambda=10$ στη συνάρτηση απώλειας του κριτή, η οποία τελικά συνδυάζει τη διαφορά μέσων τιμών (real-fake) με τον όρο penalty. Η βελτιστοποίηση πραγματοποιείται με Adam optimizer (learning rate 0.0001, βήμα $\eta=0.5$). Τα βάρη του κριτή ενημερώνονται διαδοχικά για πέντε βήματα ($N_CRITIC=5$) πριν πραγματοποιηθεί μία ενημέρωση της γεννήτριας, διασφαλίζοντας ότι ο κριτής παραμένει ισχυρός και παρέχει σταθερό feedback σε κάθε φάση της εκπαίδευσης.

Αντίστοιχα, η εκπαίδευση της γεννήτριας βασίζεται στη δημιουργία νέου batch θορύβου σε κάθε βήμα, το οποίο μετατρέπεται σε συνθετικά δείγματα και αξιολογείται από τον κριτή. Ο αρνητικός μέσος όρος των scores του κριτή στα fake samples αποτελεί τη συνάρτηση απώλειας της γεννήτριας. Ελαχιστοποιώντας αυτή την απώλεια, η γεννήτρια μαθαίνει να παράγει ολοένα και πιο ρεαλιστικά δείγματα, επιδιώκοντας να μεγιστοποιήσει το score του κριτή στα συνθετικά δεδομένα. Η ενημέρωση των βαρών της γεννήτριας γίνεται επίσης με τον Adam

optimizer, διατηρώντας σταθερές υπερπαραμέτρους για αξιοπιστία και σταθερότητα.

Καθ' όλη τη διάρκεια της εκπαίδευσης, το learning rate μειώνεται προοδευτικά κατά 1% ανά epoch, προάγοντας την ομαλή σύγκλιση του μοντέλου και αποτρέποντας φαινόμενα υπερπροσαρμογής ή ασταθούς εκπαίδευσης. Παράλληλα, τα βάρη των μοντέλων και των optimizers αποθηκεύονται συστηματικά σε checkpoints μετά από κάθε epoch, διασφαλίζοντας τη δυνατότητα επανεκκίνησης από οποιοδήποτε σημείο και την αντικειμενική αξιολόγηση της προόδου. Ιδιαίτερα σημαντικό για την παρακολούθηση της προόδου είναι το γεγονός ότι, σε κάθε epoch, τα βασικά metrics της εκπαίδευσης (D_loss, G_loss και gradient penalty) υπολογίζονται ως μέσοι όροι από όλες τις τιμές που καταγράφονται σε κάθε βήμα. Έτσι, παρέχεται μια συνολική και αντικειμενική αποτίμηση της εξέλιξης και της σταθερότητας του μοντέλου. Η συγκεκριμένη προσέγγιση, με batch size 128 και πολλαπλά βήματα ενημέρωσης του κριτή ανά ενημέρωση της γεννήτριας, διατηρεί την ισορροπία στον ανταγωνισμό μεταξύ των δύο δικτύων και οδηγεί σε σταθερή, αποδοτική και αξιόπιστη εκπαίδευση, εξασφαλίζοντας ότι τα παραγόμενα δεδομένα αναπαριστούν με ακρίβεια τα στατιστικά χαρακτηριστικά του πραγματικού συνόλου δεδομένων, ακόμα και σε απαιτητικά ή θορυβώδη περιβάλλοντα.

Η διαδικασία της εκπαίδευσης υλοποιήθηκε σε υπολογιστικό σύστημα NVIDIA DGX, εξοπλισμένο με GPU A100 SXM4 40 GB και προηγμένη αρχιτεκτονική μνήμης HBM2e με εύρος ζώνης 1,5 TB/s. Η υποδομή αυτή επιτρέπει τη φόρτωση και επεξεργασία εκατομμυρίων γραμμών δεδομένων, την απρόσκοπτη εφαρμογή κανονικοποίησης z-score, καθώς και τη δημιουργία πολύ μεγάλων batches χωρίς σφάλματα μνήμης ή bottlenecks. Τα βήματα εκπαίδευσης του κριτή και της γεννήτριας υλοποιούνται ως @tf.function (graph execution), καθώς μετατρέπει τις συναρτήσεις train_d_step και train_g_step σε TensorFlow computational graphs, προσφέροντας βελτιστοποίηση της απόδοσης, ταχύτερη εκτέλεση και αποτελεσματική αξιοποίηση της GPU. Με αυτά τα τεχνικά πλεονεκτήματα, καθίσταται εφικτή η εκτέλεση πολλαπλών epochs εκπαίδευσης, η πολυβηματική ενημέρωση του κριτή ανά βήμα της γεννήτριας, η δυναμική προσαρμογή του learning rate και η συστηματική αποθήκευση checkpoints για μεγαλύτερη αξιοπιστία. Αξίζει να σημειωθεί ότι τέτοιου είδους δυνατότητες υπερβαίνουν κατά πολύ τους τεχνικούς και χρονικούς περιορισμούς που επιβάλλονται από δωρεάν υπηρεσίες, όπως το Google Colab, προσφέροντας ένα ουσιαστικό πλεονέκτημα για την αποδοτική και αξιόπιστη εκπαίδευση μεγάλων νευρωνικών δικτύων. Για τον λόγο αυτό, επιλέχθηκε η χρήση του συστήματος NVIDIA DGX έναντι του Colab.

Συνολικά, η προσεκτική ρύθμιση των υπερπαραμέτρων, η αξιοποίηση υπολογιστικής υποδομής αιχμής και η πλήρης εναρμόνιση με τις αρχές του WGAN-GP εξασφάλισαν τη σταθερότητα και την υψηλή ποιότητα της εκπαίδευσης, επιτρέποντας τη δημιουργία συνθετικών δεδομένων που αναπαριστούν με εξαιρετική ακρίβεια τα στατιστικά χαρακτηριστικά του αρχικού συνόλου δεδομένων.

4. Αξιολόγηση Αποτελεσμάτων

4.1 Μέτρηση fidelity (Ομοιότητα με τα Πραγματικά Δεδομένα)

Η αξιολόγηση της ποιότητας των συνθετικών δεδομένων βασίζεται πρωτίστως στο κατά πόσο αυτά προσεγγίζουν τα πραγματικά δεδομένα ως προς τα βασικά στατιστικά τους χαρακτηριστικά. Για τον σκοπό αυτό, χρησιμοποιούνται τρεις καθιερωμένες μετρικές: το Μέσο Τετραγωνικό Σφάλμα (MSE), η Συνημιτονοειδής Ομοιότητα (Cosine Similarity) και η Απόκλιση Kullback-Leibler (KL Divergence).

Το **Μέσο Τετραγωνικό Σφάλμα (MSE)** καταγράφει τη μέση τετραγωνική απόσταση μεταξύ των πραγματικών και των συνθετικών τιμών. Στο παρόν πείραμα, το MSE ανέρχεται σε **0.2029**, γεγονός που υποδηλώνει μικρό σφάλμα και καλή ακρίβεια στην προσέγγιση των πραγματικών τιμών από το συνθετικό σύνολο δεδομένων. Όσο μικρότερη είναι η τιμή του MSE, τόσο μεγαλύτερη είναι η ομοιότητα μεταξύ των δύο συνόλων.

Η **Συνημιτονοειδής Ομοιότητα (Cosine Similarity)** μετρά τη γωνιακή σχέση ανάμεσα στα διανύσματα των πραγματικών και των συνθετικών δειγμάτων. Η τιμή **0.7836** υποδηλώνει πολύ καλή ομοιότητα ως προς τον προσανατολισμό των δεδομένων, δηλαδή τα συνθετικά δεδομένα ακολουθούν παρόμοια μοτίβα μεταβολής με τα πραγματικά. Τιμές κοντά στο 1 φανερώνουν σχεδόν παράλληλη κατεύθυνση και συνεπώς υψηλή συμφωνία στα στατιστικά πρότυπα.

Η **Απόκλιση Kullback-Leibler (KL Divergence)** εκφράζει το βαθμό απώλειας πληροφορίας όταν η κατανομή των συνθετικών δεδομένων χρησιμοποιείται για να προσεγγίσει την κατανομή των πραγματικών. Η παρατηρούμενη τιμή, **4.913**, υποδηλώνει ικανοποιητική προσέγγιση μεταξύ των δύο κατανομών, επιβεβαιώνοντας ότι το μοντέλο καταφέρνει να αναπαράγει τα στατιστικά χαρακτηριστικά των πραγματικών δεδομένων.

Συνεπώς, οι παραπάνω μετρικές δείχνουν ότι το WGAN-GP παράγει συνθετικά δεδομένα με υψηλή ομοιότητα ως προς τις πραγματικές τιμές και τα μοτίβα του αρχικού συνόλου, διατηρώντας ακρίβεια και πιστότητα στη στατιστική δομή των δεδομένων.

4.2 Μέτρηση diversity (Εύρος και Ποικιλία Συνθετικών Δειγμάτων)

Εκτός από την πιστότητα (fidelity), ένα άλλο κρίσιμο κριτήριο για την αξιολόγηση συνθετικών δεδομένων είναι η ποικιλία και το εύρος τους (diversity). Ένα καλό συνθετικό σύνολο δεν πρέπει μόνο να μοιάζει με το πραγματικό στατιστικά, αλλά και να παρουσιάζει επαρκή ποικιλία, ώστε να καλύπτει το πλήρες φάσμα των δυνατών περιπτώσεων που συναντώνται στα πραγματικά δεδομένα. Για τον σκοπό αυτό, χρησιμοποιούνται δύο βασικές μετρικές: η Μέση Διακύμανση (Mean Variance) και η Κάλυψη Εύρους Τιμών (Coverage).

Η **Μέση Διακύμανση (Mean Variance)** καταγράφει τη μέση τιμή της διακύμανσης ανά χαρακτηριστικό στα συνθετικά δεδομένα. Στο συγκεκριμένο πείραμα, η τιμή της διακύμανσης ανέρχεται σε 0.456, γεγονός που δηλώνει την παρουσία ικανοποιητικής ποικιλίας στις τιμές των συνθετικών δειγμάτων. Η

υπερβολικά μεγάλη διασπορά μπορεί να υποδηλώνει την ύπαρξη θορύβου, ενώ πολύ χαμηλή διακύμανση αποτελεί σαφή ένδειξη απώλειας ποικιλίας (mode collapse), καθώς το μοντέλο καταλήγει να παράγει πανομοιότυπα ή σχεδόν πανομοιότυπα δείγματα.

Η Κάλυψη Εύρους Τιμών (Coverage) μετρά το ποσοστό του εύρους τιμών των συνθετικών δεδομένων σε σχέση με το αντίστοιχο εύρος των πραγματικών δεδομένων, για κάθε χαρακτηριστικό ξεχωριστά. Η παρατηρούμενη τιμή κάλυψης, 28.46%, καταδεικνύει ότι τα συνθετικά δείγματα αναπαράγουν ένα αξιοσημείωτο υποσύνολο του συνολικού φάσματος τιμών των πραγματικών δεδομένων. Παρότι το ποσοστό αυτό αφήνει περιθώριο περαιτέρω βελτίωσης ως προς την πλήρη κάλυψη του εύρους, το αποτέλεσμα είναι ενθαρρυντικό και αποτυπώνει τη δυνατότητα του μοντέλου να διατηρεί επαρκή ποικιλία στις παραγόμενες τιμές.


Συνοψίζοντας, οι παραπάνω μετρήσεις αναδεικνύουν ότι το WGAN-GP έχει καταφέρει να παράγει συνθετικά δεδομένα με σημαντική ποικιλία και να αποφεύγει το φαινόμενο mode collapse, προσεγγίζοντας τις βασικές στατιστικές ιδιότητες του αρχικού συνόλου δεδομένων.

4.3 Ανάλυση Επιρροής Υπερπαραμέτρων στο Τελικό Αποτέλεσμα και Αξιολόγηση Αποτελέσματος

Η παραγωγή συνθετικών δειγμάτων μέσω WGAN-GP ξεκινά με τη δειγματοληψία τυχαίου θορύβου κανονικής κατανομής διαστάσεων $\text{latent_dim} = 16$, ο οποίος τροφοδοτείται στην εκπαιδευμένη γεννήτρια. Η γεννήτρια μετασχηματίζει κάθε θορυβώδες διάνυσμα σε ένα νέο συνθετικό δείγμα πέντε χαρακτηριστικών, ακολουθώντας διαδοχικά πλήρως συνδεδεμένα επίπεδα με Layer Normalization και ReLU, ώστε να μιμείται τη στατιστική και τη δομή των πραγματικών δεδομένων. Μετά την παραγωγή, τα συνθετικά δεδομένα επαναφέρονται στην αρχική κλίμακα τιμών μέσω αντίστροφης κανονικοποίησης (πολλαπλασιασμός με την τυπική απόκλιση και πρόσθεση του μέσου όρου), καθιστώντας τα συγκρίσιμα με τα αρχικά πραγματικά δεδομένα.

Η ποιότητα των συνθετικών δειγμάτων αξιολογείται τόσο ως προς τη ρεαλιστικότητα όσο και ως προς τη στατιστική τους συμπεριφορά. Ενδεικτικά, ανάλυση των παραγόμενων δειγμάτων αποκαλύπτει ότι τα πρότυπα των συνθετικών σημάτων ακολουθούν στενά τις αντίστοιχες τάσεις των πραγματικών δεδομένων, ενώ σημαντικές στατιστικές συσχετίσεις μεταξύ χαρακτηριστικών διατηρούνται και στο συνθετικό σύνολο. Αυτό καταδεικνύει την ικανότητα του WGAN-GP να αναπαράγει όχι μόνο μεμονωμένες τιμές αλλά και τη συνολική δομή

και συσχέτιση των δεδομένων.



Σχήμα 1.7: Σύγκριση Πραγματικών και Συνθετικών Δεδομένων Τηλεπικοινωνιακής Δραστηριότητας (πρώτα 100 δείγματα)

Η απόδοση και το εύρος των παραγόμενων δεδομένων εξαρτώνται ουσιαστικά από τις υπερπαραμέτρους που επιλέγονται κατά την εκπαίδευση του μοντέλου. Η επιλογή του `batch_size` ίση με 128 έγινε ώστε να επιτυγχάνεται βέλτιστη εξισορρόπηση μεταξύ σταθερότητας των `gradients`, ταχύτητας εκπαίδευσης και αποδοτικής αξιοποίησης της GPU. Η παράμετρος `LAMBDA=10.0` καθορίζει το βάρος του `gradient penalty`, διασφαλίζοντας τη διατήρηση του Lipschitz περιορισμού στον κριτή. Το `latent_dim = 16` καθορίζει τη διάσταση του διανύσματος θορύβου που εισάγεται ως είσοδος στη γεννήτρια. Η επιλογή του συγκεκριμένου μεγέθους επιτυγχάνει τη βέλτιστη ισορροπία μεταξύ υπολογιστικής αποδοτικότητας και επάρκειας ποικιλίας στα παραγόμενα δείγματα.

Ο ρυθμός μάθησης (`current_learning_rate = 0.0001`) και ο συντελεστής αδράνειας ($\beta = 0.5$) για τον Adam optimizer διασφαλίζουν ήπιες και σταθερές ενημερώσεις των βαρών τόσο του κριτή όσο και της γεννήτριας, αποφεύγοντας απότομες διακυμάνσεις που μπορεί να διαταράξουν τη διαδικασία εκμάθησης. Η σταδιακή μείωση του `learning rate` (με συντελεστή `decay_rate = 0.99` ανά epoch) συμβάλλει στην ομαλή σύγκλιση του μοντέλου, επιτρέποντας μεγαλύτερη ευελιξία στα πρώτα στάδια της εκπαίδευσης και πιο σταθερή βελτιστοποίηση όσο πλησιάζει στη σύγκλιση. Η τυχαία ανάμειξη του συνόλου δεδομένων (`dataset.shuffle(...)`) πριν το διαχωρισμό σε batches αποτρέπει το μοντέλο από το να μάθει ανεπιθύμητα ή μη-γενικεύσιμα μοτίβα. Τέλος, ο αριθμός των επαναλήψεων (`EPOCHS = 150`) παρέχει επαρκή χρόνο για τη σταδιακή προσαρμογή των παραμέτρων του δικτύου, επιτρέποντας τη σύγκλιση χωρίς να προκύπτει υπερεκπαίδευση.

Ιδιαίτερα καθοριστικός για τη σταθερότητα και την απόδοση του WGAN-GP είναι ο ρόλος της παραμέτρου `N_CRITIC`, η οποία ορίζει πόσες διαδοχικές ενημερώσεις

δέχεται ο κριτής (discriminator) για κάθε ενημέρωση της γεννήτριας (generator). Όπως προκύπτει από την πειραματική αξιολόγηση, όταν $N_CRITIC = 1$, η γεννήτρια δεν λαμβάνει επαρκώς σταθερά και πλούσια gradients από τον κριτή, με αποτέλεσμα να παράγει συνθετικά δείγματα μειωμένης ποιότητας, υψηλής διασποράς και χαμηλής πιστότητας σε σχέση με τα πραγματικά δεδομένα (παρατηρούνται υψηλότερες τιμές MSE και KL Divergence, καθώς και χαμηλότερη Cosine Similarity). Αντιθέτως, η αύξηση του N_CRITIC σε 5, όπως συνιστάται από τη διεθνή βιβλιογραφία για το WGAN-GP, επιτρέπει στον κριτή να διατηρεί ισχυρότερο εποπτικό ρόλο κατά τη διάρκεια της εκπαίδευσης και να παρέχει πιο αξιόπιστο σήμα σφάλματος στη γεννήτρια. Αυτό οδηγεί σε σαφή βελτίωση όλων των μετρικών ποιότητας: το Μέσο Τετραγωνικό Σφάλμα (MSE) παραμένει χαμηλό (0.2029), η Cosine Similarity φθάνει σε υψηλές τιμές (0.7836), η KL Divergence μειώνεται σημαντικά (4.913), ενώ ταυτόχρονα καταγράφεται επαρκής διασπορά (Mean Variance: 0.456) και ικανοποιητική κάλυψη του εύρους τιμών των πραγματικών δεδομένων (Coverage: 28.46%). Συνολικά, η επιλογή $N_CRITIC=5$ συμβάλλει καθοριστικά στη δημιουργία συνθετικών δεδομένων με υψηλή ακρίβεια, ποικιλία και πιστότητα στη στατιστική δομή του πραγματικού συνόλου δεδομένων.

Epochs	MSE	Cosine Sim.	KL Div.	Diversity	Coverage (%)
5	0.5234	0.7027	22.5015	5690.47	18.23
50	0.4754	0.7347	18.2778	3.7242	24.39
100	0.3683	0.7593	15.6313	2.2029	37.21
150	0.2029	0.7836	4.9129	0.4560	28.46
200	0.0922	0.8244	4.6045	0.0523	23.25

Πίνακας 1.1: Εξέλιξη Μετρικών Ποιότητας και Ποικιλίας των Συνθετικών Δεδομένων ανά Αριθμό Epochs

Η επίδραση των υπερπαραμέτρων και της διάρκειας της εκπαίδευσης αντανακλάται ξεκάθαρα στην εξέλιξη των βασικών μετρικών σε κάθε στάδιο των epochs. Στα πρώτα μόλις 5 epochs, το μοντέλο εμφανίζει υψηλό σφάλμα ($MSE = 0.5234$), χαμηλή Cosine Similarity (0.7027) και μεγάλη διασπορά ($Diversity = 5690.47$), ενώ η κάλυψη των πραγματικών τιμών είναι περιορισμένη ($Coverage = 18.23\%$). Στα 50 epochs, σημειώνεται αισθητή βελτίωση σε όλες τις μετρικές, αν και η συνολική απόδοση παραμένει μέτρια. Με την προοδευτική αύξηση των epochs, το μοντέλο συνεχίζει να συγκλίνει, με τις τιμές στις 100 και 150 epochs να καταγράφουν σαφή πρόοδο: το σφάλμα μειώνεται ($MSE = 0.2029$ στους 150 epochs), η συμφωνία ως προς τον προσανατολισμό των δεδομένων ενισχύεται ($Cosine\ Similarity = 0.7836$), η KL Divergence περιορίζεται σημαντικά (4.9129) και διατηρείται καλή ποικιλία χωρίς απώλεια diversity ή coverage. Αν και στους 200 epochs το MSE μειώνεται περαιτέρω και η Cosine Similarity αυξάνεται,

παρατηρείται σημαντική πτώση της διασποράς ($Diversity = 0.0523$) και της κάλυψης ($Coverage = 23.25\%$), ένδειξη πιθανής απώλειας ποικιλίας (mode collapse). Για τον λόγο αυτό, επιλέγεται ως βέλτιστο σημείο τα 150 epochs, καθώς προσφέρουν τον βέλτιστο συνδυασμό πιστότητας και ποικιλίας.

Συνολικά, η παραπάνω ανάλυση επιβεβαιώνει ότι η προσεκτική επιλογή και ρύθμιση των υπερπαραμέτρων σε συνδυασμό με κατάλληλες τεχνικές regularization και παρακολούθησης της εκπαίδευσης διαδραματίζει καθοριστικό ρόλο στην ποιότητα, την ποικιλία και τη στατιστική ακρίβεια των συνθετικών δειγμάτων που παράγει το WGAN-GP. Μέσω αυτής της μεθοδολογίας, το μοντέλο μπορεί να ανταποκριθεί αποτελεσματικά στην πρόκληση της αναπαραγωγής της πολυπλοκότητας της πραγματικής τηλεπικοινωνιακής δραστηριότητας.

5. Συμπεράσματα και Μελλοντική Έρευνα

5.1 Κύρια ευρήματα

Η παρούσα εργασία ανέδειξε τη δυναμική και την αποτελεσματικότητα της γενετικής μοντελοποίησης μέσω μιας συγκριτικής ανάλυσης από τα κλασικά GAN στα WGAN και τελικά στο WGAN-GP (Wasserstein GAN με Gradient Penalty), εστιάζοντας τόσο στις αρχιτεκτονικές όσο και στις μαθηματικές θεμελιώσεις κάθε προσέγγισης. Η μετάβαση από το GAN στο WGAN και τελικά στο WGAN-GP επέτρεψε τη σταδιακή υπέρβαση κρίσιμων προβλημάτων σταθερότητας και mode collapse, εισάγοντας νέες τεχνικές βελτιστοποίησης όπως η Wasserstein απόσταση και ο gradient penalty. Μέσα από τη συστηματική ανάλυση φάνηκε ότι η προσεκτική επιλογή αρχιτεκτονικής, υπερπαραμέτρων και τεχνικών σταθεροποίησης συντελεί καθοριστικά στη σταθερότητα της εκπαίδευσης και στην επίτευξη υψηλής ποιότητας αποτελεσμάτων. Το μοντέλο WGAN-GP κατάφερε να παράγει συνθετικά δεδομένα που προσεγγίζουν με ακρίβεια τα στατιστικά και δομικά χαρακτηριστικά των πραγματικών δεδομένων, ενώ ταυτόχρονα διατήρησε επαρκή ποικιλία, αποφεύγοντας το φαινόμενο mode collapse.

Η αξιολόγηση με μετρικές fidelity (MSE, Cosine Similarity, KL Divergence) και diversity (Mean Variance, Coverage) έδειξε ότι τα παραγόμενα συνθετικά δείγματα διατηρούν υψηλή συμφωνία με τα πραγματικά ως προς τα βασικά στατιστικά πρότυπα, ενώ παρουσιάζουν ικανοποιητικό εύρος και ποικιλία τιμών. Ιδιαίτερα στους 150 epochs, όπου επιλέχθηκε ως το βέλτιστο σημείο εκπαίδευσης, το μοντέλο πέτυχε τον καλύτερο συνδυασμό πιστότητας και ποικιλίας, προσφέροντας χαμηλό σφάλμα, υψηλή στατιστική ομοιότητα και επαρκή κάλυψη του φάσματος των πραγματικών τιμών. Η βέλτιστη ρύθμιση των παραμέτρων, όπως το batch size, το latent dimension, ο ρυθμός μάθησης και το πλήθος ενημερώσεων του κριτή, αποδείχθηκε καθοριστική για την επιτυχία του πειράματος.

Τα αποτελέσματα της εργασίας αποδεικνύουν ότι η γενετική μοντελοποίηση με GANs, και ειδικά με το WGAN-GP, μπορεί να λειτουργήσει ως ισχυρό εργαλείο για την ενίσχυση της ιδιωτικότητας και της διαθεσιμότητας δεδομένων στον τομέα

των τηλεπικοινωνιών. Η δυνατότητα παραγωγής συνθετικών δεδομένων με διατήρηση των βασικών στατιστικών και δομικών ιδιοτήτων των πραγματικών, χωρίς παραβίαση του απορρήτου, ανοίγει νέες προοπτικές, όπως η ανίχνευση ανωμαλιών, η κυβερνοασφάλεια και η ανάπτυξη λύσεων για δίκτυα επόμενης γενιάς.

5.2 Προτάσεις για Περαιτέρω Έρευνα – Μελλοντικές Μελέτες

Η αξιοποίηση του WGAN-GP για τη δημιουργία συνθετικών δεδομένων ανοίγει νέους ορίζοντες τόσο για την ερευνητική κοινότητα όσο και για τη βιομηχανία, ιδιαίτερα σε πεδία όπως τα δίκτυα 5G, όπου τα δεδομένα είναι συχνά σπάνια ή αυστηρά προστατευμένα. Προτείνεται η ενσωμάτωση μηχανισμών διαφορικής ιδιωτικότητας (Differential Privacy GANs) στη διαδικασία εκπαίδευσης. Η προσέγγιση αυτή επιτρέπει την εισαγωγή ελεγχόμενου θορύβου στα δεδομένα κατά την εκπαίδευση, περιορίζοντας τους κινδύνους επαναταυτοποίησης (reidentification risks) των πραγματικών χρηστών. Με τον τρόπο αυτό, ακόμα και σε περιβάλλοντα όπου απαιτείται υψηλή ακρίβεια, διασφαλίζεται η διατήρηση της ανωνυμίας και του απορρήτου των δεδομένων.

Ειδικά στον τομέα των δικτύων 5G, όπου τα δεδομένα είναι ταυτόχρονα πολύτιμα και ευαίσθητα (όπως δεδομένα τοποθεσίας, χρήσης εφαρμογών και μοτίβα επικοινωνίας), το WGAN-GP προσφέρει τη δυνατότητα παραγωγής δειγμάτων που μιμούνται τα βασικά στατιστικά και χρονικά χαρακτηριστικά των πραγματικών δεδομένων, χωρίς να συσχετίζονται με συγκεκριμένους χρήστες ή συσκευές. Αυτό καθιστά εφικτή την ασφαλή διαμοίραση δεδομένων για ερευνητικούς σκοπούς, ανάπτυξη και benchmarking, χωρίς να παραβιάζονται οι κανονισμοί προστασίας προσωπικών δεδομένων.

Επιπλέον, στα δίκτυα 5G, η διαθεσιμότητα μεγάλων και ποικίλων συνόλων δεδομένων είναι κρίσιμη για την εκπαίδευση συστημάτων μηχανικής μάθησης, την ανίχνευση επιθέσεων και τη βελτιστοποίηση των παρεχόμενων υπηρεσιών. Η χρήση του WGAN-GP για την παραγωγή ποιοτικών συνθετικών δεδομένων (data augmentation) μπορεί να ενισχύσει τα υφιστάμενα σύνολα δεδομένων, να περιορίσει το φαινόμενο του overfitting και να αυξήσει τη γενικευσιμότητα των μοντέλων σε σπάνιες ή άγνωστες περιπτώσεις.

Συνολικά, η ερευνητική δραστηριότητα σε αυτό το πεδίο έχει τη δυναμική να προσφέρει καινοτόμες μεθόδους και εργαλεία, τα οποία θα συμβάλουν στην ασφάλεια, την προστασία της ιδιωτικότητας και τη βελτίωση των υπηρεσιών στα δίκτυα επόμενης γενιάς.

5.3 Επίκαιρη Εφαρμογή - Ρεαλιστικό Παράδειγμα

Η πρακτική αξία του προτεινόμενου μοντέλου υπερβαίνει τα στενά όρια της θεωρητικής έρευνας και της απλής παραγωγής δεδομένων για πειραματικούς σκοπούς. Στη σύγχρονη εποχή, η ραγδαία εξάπλωση των δικτύων 5G και η εκθετική αύξηση του όγκου της δικτυακής κίνησης καθιστούν κρίσιμη την ανάγκη για αποτελεσματική ανίχνευση ανωμαλιών σε τηλεπικοινωνιακές υποδομές. Τα


δίκτυα 5G, λόγω των εξαιρετικά υψηλών ταχυτήτων, της αυξημένης χωρητικότητας και της μαζικής διασύνδεσης συσκευών, μετατρέπονται σε στόχο ολόένα και πιο σύνθετων και εξελιγμένων κυβερνοεπιθέσεων. Οι παραδοσιακές μέθοδοι ανίχνευσης εισβολών, που βασίζονται σε στατικούς κανόνες ή σε ιστορικά δεδομένα, συχνά αποτυγχάνουν να εντοπίσουν σπάνιες ή νέες μορφές επιθέσεων, οι οποίες εκμεταλλεύονται τα καινοτόμα χαρακτηριστικά των 5G δικτύων.

Η δημιουργία συνθετικών δεδομένων δικτυακής κίνησης μέσω WGAN-GP μπορεί να ενισχύσει σημαντικά την εκπαίδευση συστημάτων ανίχνευσης ανωμαλιών, βελτιώνοντας την ικανότητα ταξινόμησης επιθέσεων ακόμη και όταν ορισμένες κατηγορίες είναι υποεκπροσωπούμενες. Η χρήση αυτών των συνθετικών δεδομένων συμβάλλει στην αντιμετώπιση του προβλήματος της ανισορροπίας κατηγοριών και ενισχύει τη δυνατότητα εντοπισμού σπάνιων ή άγνωστων τύπων επιθέσεων, αυξάνοντας τη συνολική ακρίβεια των συστημάτων σε πραγματικές συνθήκες.

Ένα ρεαλιστικό σενάριο εφαρμογής αφορά την ανίχνευση ανωμαλιών και επιθέσεων σε τηλεπικοινωνιακά δίκτυα, όπως DDoS ή εκτεταμένες διακοπές υπηρεσιών, σε πραγματικό χρόνο. Σε αυτό το πλαίσιο, το WGAN-GP εκπαιδεύεται αποκλειστικά σε «κανονικά» δείγματα CDR (Call Detail Records), με αποτέλεσμα ο κριτής να λειτουργεί ως ανιχνευτής ανωμαλιών (anomaly detector), με το Wasserstein loss να αξιοποιείται ως μέτρο απόκλισης από το φυσιολογικό πρότυπο. Κάθε νέο δείγμα κίνησης αξιολογείται ως προς την απόκλισή του, και σε περίπτωση σημαντικής απόκλισης (υψηλό loss) ανιχνεύεται πιθανή ανωμαλία ή επίθεση.

Η αρχιτεκτονική αυτή ενσωματώνει Convolutional Neural Network (CNN) στον κριτή του WGAN-GP, αξιοποιώντας διαδοχικά Conv1D layers, max-pooling και dense layers για την αυτόματη εξαγωγή χωροχρονικών χαρακτηριστικών από τα δεδομένα. Έτσι, ο κριτής μπορεί να διαχωρίζει με μεγαλύτερη ακρίβεια τα κανονικά από τα συνθετικά ή ανώμαλα δείγματα, ακόμα και σε δεδομένα με πολύπλοκα μοτίβα. Παράλληλα, το CNN ενσωματώνεται και στο classification head του συστήματος, το οποίο χρησιμοποιείται για την πολυκατηγορική ταξινόμηση (multi-category classification) επιθέσεων. Η δυνατότητα των CNNs να αναγνωρίζουν αφηρημένα και πολυπαραγοντικά μοτίβα στα δεδομένα αποδεικνύεται κρίσιμη για τον εντοπισμό και τη σωστή κατηγοριοποίηση ακόμα και σύνθετων ή άγνωστων επιθέσεων.

Αυτή η λύση έχει ιδιαίτερη σημασία για την ασφάλεια και διαθεσιμότητα τηλεπικοινωνιακών υποδομών, ειδικά σε χώρες και αγορές με υψηλή δικτυακή δραστηριότητα, όπως η Ισπανία, η Πορτογαλία ή το Μαρόκο. Στο πρόσφατο περιστατικό μαζικών διακοπών υπηρεσιών ή στοχευμένης κυβερνοεπίθεσης, ένα τέτοιο σύστημα θα μπορούσε να ανιχνεύσει έγκαιρα την ανωμαλία χωρίς να απαιτείται η ύπαρξη ετικετοποιημένων ιστορικών επιθέσεων (labeled datasets). Η εκπαίδευση βασίζεται αποκλειστικά σε υγιή πρότυπα κίνησης, με κάθε απόκλιση να ενεργοποιεί αυτόματα τη λήψη μέτρων προστασίας, εξοικονομώντας πολύτιμο χρόνο και πόρους για παρόχους και διαχειριστές.



Σχήμα 1.8: Αρχιτεκτονική WGAN-GP για Ανίχνευση Ανωμαλιών σε Τηλεπικοινωνιακά Δίκτυα 5G – Ροή Εφαρμογής και Πρακτικό Παράδειγμα Χρήσης

Συνεπώς, το WGAN-GP αναδεικνύεται ως καταλύτης για την έγκαιρη ανίχνευση και πρόληψη τηλεπικοινωνιακών απειλών σε περιβάλλοντα 5G, προσφέροντας ένα πρακτικό, ισχυρό και επεκτάσιμο εργαλείο για την ενίσχυση της ασφάλειας και της διαθεσιμότητας των σύγχρονων δικτυακών υποδομών.

6. Βιβλιογραφία

Ian J. Goodfellow, Jean Pouget-Abadie, Mehdi Mirza, Bing Xu, David Warde-Farley, Sherjil Ozair, Aaron Courville, and Yoshua Bengio. 2014. Generative Adversarial Networks. arXiv preprint arXiv:1406.2661. DOI: <https://doi.org/10.48550/arXiv.1406.2661BibSonomy+2arXiv+2ResearchGate+2>

Ishaan Gulrajani, Faruk Ahmed, Martin Arjovsky, Vincent Dumoulin, and Aaron Courville. 2017. Improved Training of Wasserstein GANs. arXiv preprint arXiv:1704.00028. DOI: <https://doi.org/10.48550/arXiv.1704.00028arXiv+13arXiv+13Reddit+13>

I. Toutate. 2025. Pro-Russian hackers claim responsibility for major power outage across Spain, Portugal. Morocco World News. (April 29, 2025). <https://www.moroccoworldnews.com/2025/04/195208/pro-russian-hackers-claim-responsibility-for-major-power-outage-across-spain-portugal/>

Liyuan Lu. 2024. An Empirical Study of WGAN and WGAN-GP for Enhanced Image Generation. Applied and Computational Engineering, 83(1), 103–109. DOI: <https://doi.org/10.54254/2755-2721/83/2024GLG0066>

Martin Arjovsky, Soumith Chintala, and Léon Bottou. 2017. Wasserstein GAN. arXiv preprint arXiv:1701.07875. DOI: <https://doi.org/10.48550/arXiv.1701.07875arXiv+8arXiv+8arXiv+8>

Spencer Frei, Gal Vardi, Peter Bartlett, Nathan Srebro, and Wei Hu. 2023. Implicit Bias in Leaky ReLU Networks Trained on High-Dimensional Data. In Proceedings of the 11th International Conference on Learning <https://openreview.net/forum?id=JpbLyEI5EwW>

Victor M. Panaretos and Yoav Zemel. 2019. Statistical Aspects of Wasserstein Distances. Annual Review of Statistics and Its Application, 6(1), 405–431. arXiv preprint arXiv:1806.05500. DOI: <https://doi.org/10.48550/arXiv.1806.05500arXiv+2arXiv+2arXiv+2>